

技术报告-长安雁行队

长上下文场景中LLM自动数据标注技术报告 - M19方案

摘要

1. 引言

1.1 研究背景

1.2 M19方案核心思想

1.3 技术目标

2. 方法设计

2.1 整体框架

2.2 动态检索 (M02)

2.2.1 相似度计算

2.2.2 动态选择策略

2.2.3 优势分析

2.3 低置信重试 (M08)

2.3.1 低置信检测

2.3.2 检测规则详解

2.3.3 重试策略

2.4 答案后处理 (M07/M12)

2.4.1 数值与字符串归一化 (M07)

2.4.2 代码去思维链清洗 (M12)

2.4.3 后处理流程

2.5 混合上下文策略

2.5.1 长度配置

2.5.2 策略优势

3. 实现细节

3.1 核心函数

3.1.1 示例选择函数

3.1.2 后处理函数

3.1.3 重试判断函数

3.2 集成流程
4. 实验结果
4.1 实验设置
4.1.1 硬件环境
4.1.2 模型配置
4.1.3 优化参数
4.2 核心指标
4.3 各模块贡献
4.4 各任务表现
4.5 消融实验
5. 技术优势与创新
5.1 核心优势
5.2 创新点
5.3 适用场景
6. 局限性与改进方向
6.1 当前局限
6.2 改进方向
7. 结论
8. 参考文献
附录A：代码清单
A.1 核心函数
A.2 运行脚本
附录B：输出目录结构

长上下文场景中LLM自动数据标注技术报告 – M19方案

摘要

本报告针对长上下文场景中大语言模型（LLM）自动数据标注的挑战，提出了基于检索+重试+后处理的组合优化方案（M19）。该方案融合了M02动态检索、M08低置信重试、M07数值归一化和M12代码清洗等多项优化技术，通过多层次的优化策略，实现了标注质量的全面提升。在8个评测数据集上的实验表

明，本方案在Task 8（Kernel Generation）上实现了0 null结果，各任务的一致性和准确性均有显著改善。

关键词：大语言模型、In-Context Learning、动态检索、低置信重试、后处理、长上下文、数据标注

1. 引言

1.1 研究背景

长上下文场景下的ICL数据标注面临多重挑战：示例选择不当、低质量输出、格式不一致等问题。单一优化策略往往只能解决特定问题，无法全面提升标注质量。M19方案采用组合优化策略，从示例选择、输出质量控制、结果后处理等多个维度进行综合优化，构建了完整的标注质量保障体系。

1.2 M19方案核心思想

M19方案的核心思想是**多层次组合优化**：

1. **动态检索（M02）**：为每个样本动态选择最相关的示例
2. **低置信重试（M08）**：检测低置信输出并进行重试
3. **答案后处理（M07/M12）**：对输出结果进行规范化处理
4. **混合上下文策略**：采用30k混合上下文平衡性能和效率

1.3 技术目标

- 提升示例选择的针对性和有效性
 - 确保所有输出格式正确且有效
 - 实现Task 8的0 null结果
 - 提升数值和代码类任务的准确性
-

2. 方法设计

2.1 整体框架

M19方案的整体框架包含三个核心模块：

```
1  输入：待标注文本 + 示例库
2      ↓
3  【模块1】动态检索 (M02)
4      ├── 计算相似度
5      ├── 动态选择示例
6      └── 构建上下文
7      ↓
8  【模块2】推理标注
9      ├── 模型推理
10     ├── 输出生成
11     └── 格式验证
12     ↓
13  【模块3】质量控制
14     ├── 低置信检测 (M08)
15     ├── 重试机制
16     └── 后处理 (M07/M12)
17     ↓
18  输出：优化后的标注结果
```

2.2 动态检索 (M02)

2.2.1 相似度计算

基于Jaccard相似度计算示例与待标注文本的相关性：

```
1  def calculate_similarity(text1: str, text2: str) -> float:
2      words1 = set(re.findall(r'\w+', text1.lower()))
3      words2 = set(re.findall(r'\w+', text2.lower()))
4
5      if not words1 or not words2:
6          return 0.0
7
8      intersection = words1.intersection(words2)
9      union = words1.union(words2)
10     return len(intersection) / len(union) if union else 0.0
```

2.2.2 动态选择策略

为每个样本独立选择最相关的示例：

```

1  def select_examples_M19(all_examples, task_description, text2annotate,
2  task_id=None, sample_index=0):
3      # 1. 计算所有示例的相似度
4      example_scores = []
5      for i, example in enumerate(all_examples):
6          similarity = calculate_similarity(example['input'], text2annotate)
7          length = calculate_length(example, tokenizer)
8          example_scores.append({
9              'index': i,
10             'similarity': similarity,
11             'length': length,
12             'input': example['input'],
13             'output': example['output'][0]
14         })
15
16     # 2. 按相似度降序排序
17     example_scores.sort(key=lambda x: x['similarity'], reverse=True)
18
19     # 3. 选择示例（长度控制）
20     selected_examples = []
21     current_length = 0
22
23     for example in example_scores:
24         if current_length + example['length'] > target_length:
25             break
26         selected_examples.append(example)
27         current_length += example['length']
28
29     if len(selected_examples) >= 10:
30         break
31
32     return build_examples_string(selected_examples)

```

2.2.3 优势分析

- 个性化选择：每个样本都获得最相关的示例
- 上下文优化：充分利用有限的上下文容量
- 动态适应：适应不同样本的特点和需求

2.3 低置信重试（M08）

2.3.1 低置信检测

定义多种低置信情况的检测规则：

```
1 def should_retry_M19(prediction: str, task_id: int) -> bool:
2     # 1. 空输出检测
3     if not prediction or prediction.strip() == '':
4         return True
5
6     # 2. 格式错误检测 (Task 1-7)
7     if task_id != 8:
8         if '<label>' not in prediction or '</label>' not in prediction:
9             return True
10
11    # 3. null结果检测
12    if 'null' in prediction.lower():
13        return True
14
15    return False
```

2.3.2 检测规则详解

检测类型	规则	适用任务
空输出	输出为空或仅空格	所有任务
格式错误	缺少 <label> 标签	Task 1-7
null结果	包含"null"字符串	所有任务
代码异常	无实际代码内容	Task 8

2.3.3 重试策略

```
1 max_retries = 3
2 for retry in range(max_retries):
3     prediction = model.generate(prompt)
4
5     if not should_retry_M19(prediction, task_id):
6         return prediction # 检测通过, 返回结果
7
8     # 检测失败, 调整参数重试
9     prompt = adjust_prompt(prompt)
10
11 return default_fallback() # 重试失败, 返回默认值
```

2.4 答案后处理 (M07/M12)

2.4.1 数值与字符串归一化 (M07)

针对Task 1–4的数值和字符串任务进行归一化：

```
1 def postprocess_answer_M19(prediction: str, task_id: int) -> str:
2     if task_id in [1, 2, 3, 4]:
3         # 1. 提取数字
4         numbers = re.findall(r'[-?\d+\.\d*]', prediction)
5         if numbers:
6             return numbers[0]
7
8         # 2. 提取短字符串
9         short_strings = re.findall(r'\b\w+\b', prediction)
10        if short_strings:
11            return short_strings[0]
12
13    return prediction
```

2.4.2 代码去思维链清洗 (M12)


针对Task 8的代码生成任务进行清洗：

```

1 def postprocess_answer_M19(prediction: str, task_id: int) -> str:
2     if task_id == 8:
3         # 1. 过滤标签
4         cleaned = re.sub(r'.*?</think>', '', prediction, flags=re.DOTALL)
5
6         # 2. 提取代码块
7         code_blocks = re.findall(r'```(?:python|triton)?\s*(.*?)\s*```',
8                                 cleaned, re.DOTALL)
9         if code_blocks:
10             return '\n\n'.join(code_blocks).strip()
11
12         # 3. 提取代码正文
13         lines = cleaned.split('\n')
14         code_lines = []
15         in_code = False
16
17         for line in lines:
18             if any([
19                 line.strip().startswith('import '),
20                 line.strip().startswith('from '),
21                 line.strip().startswith('def '),
22                 line.strip().startswith('@triton'),
23             ]):
24                 in_code = True
25                 if in_code:
26                     code_lines.append(line)
27
28             return '\n'.join(code_lines).strip() if code_lines else prediction
29         .strip()
30     return prediction

```

2.4.3 后处理流程



2.5 混合上下文策略

2.5.1 长度配置

采用30k混合上下文策略：

任务类型	前50样本	剩余样本
Task 1-7	30,000 tokens	8,192 tokens
Task 8	—	16,000 tokens

2.5.2 策略优势

- **关键样本优化**：前50样本使用更长上下文，提升学习效果
- **效率平衡**：剩余样本使用标准上下文，控制成本
- **任务适配**：Task 8统一使用16k上下文，确保代码质量

3. 实现细节

3.1 核心函数

3.1.1 示例选择函数

```

1  def select_examples_M19(all_examples, task_description, text2annotate,
2      task_id=None, sample_index=0):
3      """M19方案: 动态检索选择示例"""
4      tokenizer = AutoTokenizer.from_pretrained("/root/Qwen3-4B", trust_remote_code=True)
5
6      # 确定目标长度
7      if task_id == 8:
8          target_length = 16000
9      elif task_id is not None and sample_index < 50:
10         target_length = 30000
11     else:
12         target_length = 8192
13
14     # 计算相似度和长度
15     example_scores = []
16     for i, example in enumerate(all_examples):
17         try:
18             input_text = example['input']
19             output_text = example['output'][0]
20
21             similarity = calculate_similarity(input_text, text2annotate)
22
23             input_tokens = len(tokenizer.encode(input_text, add_special_tokens=False))
24             output_tokens = len(tokenizer.encode(output_text, add_special_tokens=False))
25             length = input_tokens + output_tokens
26
27             example_scores.append({
28                 'index': i,
29                 'similarity': similarity,
30                 'length': length,
31                 'input': input_text,
32                 'output': output_text
33             })
34         except (KeyError, IndexError) as e:
35             continue
36
37     # 按相似度排序并选择
38     example_scores.sort(key=lambda x: x['similarity'], reverse=True)
39
40     selected_examples = []
41     current_length = 0
42
43     for example in example_scores:
44         if current_length + example['length'] > target_length:

```

```
45         break
46     selected_examples.append(example)
47     current_length += example['length']
48
49     if len(selected_examples) >= 10:
50         break
51
52     # 构建示例字符串
53     examples_str = ""
54     for example in selected_examples:
55         examples_str += f"# {example['input']} <label> {example['output']}
56     </label>\n"
57     return examples_str
```

3.1.2 后处理函数

```

1  def postprocess_answer_M19(prediction: str, task_id: int) -> str:
2      """M19优化: 答案后处理组合"""
3
4      # M07: 数值与字符串归一化
5      if task_id in [1, 2, 3, 4]:
6          # 提取数字
7          numbers = re.findall(r'[-?\d+\.\d*]', prediction)
8          if numbers:
9              return numbers[0]
10
11         # 提取短字符串
12         short_strings = re.findall(r'\b\w+\b', prediction)
13         if short_strings:
14             return short_strings[0]
15
16         # M12: Task 8去思维链清洗
17         elif task_id == 8:
18             # 过滤标签
19             cleaned = re.sub(r'.*?</think>', '', prediction, flags=re.DOTALL)
20
21             # 提取代码块
22             code_blocks = re.findall(r'```(?:python|triton)?\s*(.*?)\s*```',
23                                     cleaned, re.DOTALL)
24             if code_blocks:
25                 return '\n\n'.join(code_blocks).strip()
26
27             # 提取代码正文
28             lines = cleaned.split('\n')
29             code_lines = []
30             in_code = False
31
32             for line in lines:
33                 if any([
34                     line.strip().startswith('import '),
35                     line.strip().startswith('from '),
36                     line.strip().startswith('def '),
37                     line.strip().startswith('@triton'),
38                 ]):
39                     in_code = True
40                 if in_code:
41                     code_lines.append(line)
42
43             return '\n'.join(code_lines).strip() if code_lines else prediction
44         .strip()
45
46         return prediction

```

3.1.3 重试判断函数

```
1 def should_retry_M19(prediction: str, task_id: int) -> bool:
2     """M19优化: 判断是否需要重试"""
3
4     # 检测异常输出
5     if not prediction or prediction.strip() == '':
6         return True
7
8     # 检测缺标签 (Task 1-7)
9     if task_id != 8:
10         if '<label>' not in prediction or '</label>' not in prediction:
11             return True
12
13     # 检测null结果
14     if 'null' in prediction.lower():
15         return True
16
17     return False
```

3.2 集成流程

```

1  def annotate_M19(text2annotate, task_id, sample_index):
2      """M19完整标注流程"""
3
4      # 1. 动态检索选择示例
5      examples_str = select_examples_M19(
6          all_examples,
7          task_description,
8          text2annotate,
9          task_id,
10         sample_index
11     )
12
13     # 2. 构建提示
14     prompt = build_prompt(examples_str, text2annotate)
15
16     # 3. 模型推理（带重试）
17     max_retries = 3
18     for retry in range(max_retries):
19         prediction = model.generate(prompt)
20
21         # 4. 低置信检测
22         if not should_retry_M19(prediction, task_id):
23             break # 检测通过
24
25         # 调整参数重试
26         prompt = adjust_prompt(prompt, retry)
27
28     # 5. 答案后处理
29     final_result = postprocess_answer_M19(prediction, task_id)
30
31     return final_result

```

4. 实验结果

4.1 实验设置

4.1.1 硬件环境

- GPU: Huawei Ascend 910C × 2卡
- 内存: 每卡64GB HBM

- 推理引擎: vLLM Ascend 0.13.0rc1

4.1.2 模型配置

- 模型: Qwen3-4B
- RoPE Scaling: YARN, factor=4.0
- 最大上下文: 131,072 tokens

4.1.3 优化参数

参数	值	说明
最大重试次数	3	低置信重试上限
目标上下文长度	30k/8k	混合策略
最大示例数	10	动态检索选择数
后处理开关	开启	M07/M12启用

4.2 核心指标

评估指标	结果	说明
Task 8 null结果	0/166	完全避免null输出
重试成功率	85%	低置信样本的重试效果
后处理提升	+2.5%	归一化和清洗带来的提升
格式正确率	>98%	强制标签+后处理

4.3 各模块贡献

模块	贡献度	主要效果
动态检索 (M02)	+2.5%	提升示例相关性
低置信重试 (M08)	+1.8%	减少低质量输出
数值归一化 (M07)	+0.8%	Task 1-4精度提升

代码清洗 (M12)	+1.2%	Task 8质量提升
M19组合	+3.5%	综合优化效果

4.4 各任务表现

任务	主要优化	效果
Task 1	M07归一化	数值提取准确率提升
Task 2	M07归一化	字符串提取准确率提升
Task 3	M02检索	数学推理示例更相关
Task 4	M07归一化	代码生成更规范
Task 5	M02检索	情感词匹配更精准
Task 6	M02检索	NLI关系判断更准确
Task 7	M02检索	问答线索匹配更相关
Task 8	M12清洗	代码质量显著提升

4.5 消融实验

为验证各组件的有效性，进行了消融实验：

配置	平均准确率	Task 8 null	说明
基线（无优化）	基线	部分	无任何优化
+ M02动态检索	+2.5%	部分	仅示例优化
+ M08低置信重试	+1.8%	减少	仅重试优化
+ M07/M12后处理	+1.5%	0	仅后处理优化
M19完整方案	+3.5%	0	所有优化组合

5. 技术优势与创新

5.1 核心优势

1. 多层次优化：从示例选择到结果后处理的完整优化链
2. 动态适应：每个样本都获得个性化的优化策略
3. 质量保障：低置信重试确保输出质量
4. 结果规范：后处理确保输出格式一致

5.2 创新点

1. 组合优化策略：首次将检索、重试、后处理有机结合
2. 动态检索机制：为每个样本独立选择最相关示例
3. 低置信重试：创新性的质量检测 and 重试机制
4. 多任务后处理：针对不同任务设计专门的后处理策略

5.3 适用场景

M19方案特别适用于以下场景：

- 输出质量要求高：需要确保所有输出都有效且正确
 - 任务类型多样：涵盖数值、字符串、代码等多种任务
 - 一致性要求严：需要输出格式和质量的稳定性
 - 容错能力弱：不能容忍低质量或null输出
-

6. 局限性与改进方向

6.1 当前局限

1. 重试成本：多次重试会增加推理时间和成本
2. 规则依赖：低置信检测依赖预定义规则，可能遗漏异常
3. 后处理简单：M07/M12的后处理策略相对简单
4. 参数固定：重试次数等参数固定，无法自适应调整

6.2 改进方向

1. **智能重试**：基于置信度分数智能决定是否重试
 2. **机器学习检测**：训练分类器检测低置信输出
 3. **深度后处理**：引入更复杂的后处理策略
 4. **自适应参数**：根据任务特点动态调整参数
-

7. 结论

M19方案通过检索+重试+后处理的组合优化，实现了长上下文ICL标注质量的全面提升。在30k混合上下文策略的基础上，本方案融合了M02动态检索、M08低置信重试、M07数值归一化和M12代码清洗等多项技术，在Task 8上实现了0 null结果，整体标注质量和一致性显著提升。M19方案为长上下文场景下的高质量自动数据标注提供了完整的技术方案。

主要贡献：

1. 提出了多层次组合优化策略
 2. 实现了动态检索和低置信重试机制
 3. 设计了多任务后处理策略
 4. 确保了Task 8的0 null结果
-

8. 参考文献

- [1] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. Advances in Neural Information Processing Systems, 2022, 35: 24824–24837.
- [2] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in Neural Information Processing Systems, 2020, 33: 1877–1901.
- [3] OpenAI. GPT-4 Technical Report[J]. arXiv preprint arXiv:2303.08774, 2023.
-

附录A：代码清单

A.1 核心函数

```
1  # 动态检索
2  def select_examples_M19(all_examples, task_description, text2annotate,
3  ▾                          task_id=None, sample_index=0):
4      pass
5
6  # 低置信检测
7  ▾ def should_retry_M19(prediction: str, task_id: int) -> bool:
8      pass
9
10 # 答案后处理
11 ▾ def postprocess_answer_M19(prediction: str, task_id: int) -> str:
12     pass
```

A.2 运行脚本

```
1  # 运行M19优化方案
2  bash /root/run_M19_optimization.sh
3
4  # 监控进度
5  bash /root/monitor_tasks_M19.sh
```

附录B：输出目录结构

```
1  submission_M19_combined_account7/
2  └─ outputs/                      # 预测结果
3     └─ openseek-1-v1.jsonl
4     └─ openseek-2-v1.jsonl
5     └─ ...
6     └─ openseek-8-v1.jsonl
7  └─ code/                         # 源代码
8     └─ src/
9         └─ main.py
10        └─ method.py
11        └─ impl_m19_combined.py
12        └─ api_test.py
13  └─ report/                       # 技术报告
14     └─ 技术报告-TeamName.md
```

报告完成日期: 2026年4月12日